

Biznis prilike sa vještačkom inteligencijom

Jasmin Jahić

[Prolog 2026](#)

26.09.2026

jj542@cam.ac.uk

O meni



- Univerzitet u Tuzli
- Ecole Centrale de Nantes, Nantes
- Rheinland-Pfälzische Technische Universität Kaiserslautern-Landau, Kaiserslautern
- Fraunhofer Institute for Experimental Software Engineering, Kaiserslautern
- Direktor studija za računarstvo, Queens' koledž, Univerzitet u Kembridžu, Velika Britanija
- Predavač i istraživač, Odsjek za računarstvo, Univerzitet u Kembridžu, Velika Britanija
- <https://jahic.github.io/prolog2026>

Sažetak

Uvod u generativnu vještačku inteligenciju (GenAI – Generative Artificial Intelligence)

GenAI kao konsultant

GenAI i napredni zadaci

GenAI i biznis



Uvod u generativnu vještačku inteligenciju (GenAI – Generative Artificial Intelligence)

Interfejs između ljudi i mašina (HMI – Human Machine Interface)



Mozak računara su procesori (Central Processing Unit – CPU)

Tranzistori: osnovni elementi od kojih su napravljeni procesori

Tranzistor je elektronski element koji se ponaša kao (izuzetno brz) prekidač – otvoreno, zatvoreno – nula ili jedinica - 0, 1

Komunikacija sa računarima mora se odvijati koristeći nule i jedinice – sve mora biti prevedeno u binarni jezik – konfiguracija uslovljena tranzistorima

Interfejs između ljudi i mašina (HMI – Human Machine Interface)



Npr. AMD Ryzen 9000 - preko 8 milijardi tranzistora

Interfejs između ljudi i mašina (HMI – Human Machine Interface)

- Uspostavljanje komunikacije između ljudi i mašina: programi koji prevode prirodni jezik i ljudske namjere u binarni jezik (nule i jedinice)
- Korištenje programa koji omogućavaju ograničenu interakciju te su napravljeni da omoguće prijevod prirodnog jezika u binarni jezik
 - Web stranice
 - Mobilne aplikacije
 - Uredski alati (npr. Word)
- Programiranje: pisanje programa – zapisivanje namjera – komandi – koje računari trebaju izvršiti

Programiranje

- Napisati program (izvorni kod – source code) u obliku (još uvijek) razumljivom ljudima
- Korištenje drugih programa koji prevode izvorni kod u binarni (tzv. kompajleri)
- Način komunikacije sa računarima „rezervisan“ za one koji znaju kako programirati
 - U suprotnom, ljudi mogu koristiti samo unaprijed isprogramirane operacije
 - Npr. ako želimo da u Word dokumentu drugo slovo svake riječi postane veliko – nemamo tu opciju
- Postoji li neki alat van programiranja koji može razumijeti ono što želite, kreirati rješenja, te komunicirati ta rješenja sa računarom i zahtijevati da se izvrše

Vještačka inteligencija i GenAI

Turingov test: ako komunicirate preko 2 terminala (chat), gdje jednim terminalom upravlja čovjek a drugim softverski program, da li možete razlikovati za kojim terminalom je čovjek a kojim upravlja softverski program? Ako ne, onda je program inteligentan.

Mašinsko učenje (machine learning): Računar uči iz iskustva I, u kontekstu zadatka Z koji obavlja sa uspjehom U, ako uspije unaprijediti uspjehnost U obavljanja zadatka Z kako stiče iskustvo I.


Large Language Models - LLM-ovi su bazirani na vrsti neuronske mreže „Transformeri“ i skoro ekskluzivno generišu tekstualni sadržaj.

Transformeri su uveli pojam „nivoi pažnje“ (attention scores) omogućavajući fokus na relevantne podatke i povezivanje istih.


Sub-symbolic AI captures knowledge implicitly in numerical patterns and complex structures (and not in hard coded rules), allowing conclusions to emerge. This allows flexibility when dealing with uncertainty.

Neuralna mreža je paralelizovani procesor sa mogućnošću čuvanja i korištenja znanja.


GenAI je tip neuronske mreže sposoban za proizvodnju novog sadržaja (tekst, slike, zvuk)



Neuralne mreže



- Weights - težina: određuje koliko jedan neuron utiče na drugi.
- Bias - pristrasnost: nelinearna funkcija neurona.
- Probabilities - vjerovatnoća (između 0 i 1)
- **Randomness - nasumičnost**
- **Trening**: podešavanje težina i pristrasnosti na osnovu velike količine podataka (nadgledano i nenadgledano učenje)
- **Broj parametara**: težine i pristrasnosti
- Treniranje na dostupnim podacima
- Token: najmanja jedinica ulaza/izlaza. Npr., „Dobar sažetak AI-a“ -> „Dobar“, „sažetak“, „AI-a“), ili dalje „dobar“ -> „do“, „bar“).
- **Inference - inferenca**: proces dobijanja izlaza primjenom modela na ulazne podatke – šta je sljedeći token?



Osobine LLM-ova

Kontekst: ('radna memorija') količina podataka koju GenAI model može prihvatiti i čuvati. Modeli mogu selektivno zaboraviti dijelove konteksta.

Guardrails – mehanizmi koji sprječavaju model da odgovori na određena pitanja. Npr., sigurnosno-kritična pitanja.

Privatnost podataka: prikupljanje i korištenje podataka koji protiču kroz LLM definisani su ugovorom sa pružiocima usluga. Zlatno pravilo: jednom online, uvijek online!

Prompt je ulaz u GenAI sistem.

Vjerovatnoća: vjerovatnoća da će se određeni događaj desiti, decimalni brojevi između 0 i 1.

Retrieval-augmented generation (RAG): dobavljanje dodatnih podataka iz eksternih izvora (linkovi, dokumenti) i kombinacija sa modelom.


GenAI u kontekstu interakcije ljudi i mašina

Algoritmi i funkcije transformacije podataka


Ulaz $\rightarrow$ f $\rightarrow$ Izlaz

Dizajniraj i implementiraj transformacije ulaza i izlaza: algoritmi

Muhammad ibn Musa al-Khwarizmi (780 - 850)



Primjer algoritma – pronalazak najmanjeg broja



GenAI u poređenju sa algoritmima

- Algoritmi
 - Formalno definisani – matematske funkcije: transformacije ulaza u izlaz
 - Rezultati koji se mogu ponoviti
 - Nefleksibilna pravila: Npr., “Korisnik” ili “Korsnk”. Nisu pogodni za interpretaciju i generalizaciju. Npr. praćenje apstraktnih odluka dizajna u implementaciji u izvornom kodu.
- GenAI
 - Rezultati bazirani na statistici i nasumičnosti
 - Nizak nivo ponovljivosti rezultata
 - Visok nivo fleksibilnosti: Pogodna tehnologija za slučajeve gdje postoji ogroman broj opcija i pravila. Pogodna tehnologija za interpretaciju i generalizaciju. Npr., „razumijevanje“ koji dijelovi koda implementiraju koju odluku konceptualnog dizajna.

GenAI in the context of Human- Computer Interaction

Programiranje: pisanje algoritma koristeći programske jezike


LLM-ovi: inferencija izlaza na osnovu ulaza koristeći trenirani model

Oba pristupa upravljaju računarima da urade ono što od njih očekujemo

Algoritmi rade tačno ono za što su programirani

LLM-ovi mogu uraditi mnogo više

Properties of GenAI



GenAI properties

- Randomness and probability
- Data diversity and data quality
- Model recency
- Controllability
- Ethical and legal compliance, censorship (guardrails)
- Interpretability and explainability
- Response time
- Generalization ability
- Parameter count
- Scaling and memory
- Robustness
- Factuality and calibration

Mogućnosti GenAI

- Pristup znanju
- Prijedlozi inovativnih rješenja
- Identifikacija kompleksnih zavisnosti i anomalija
- Prijedlozi optimizovanih rješenja
- Personalizacija
- Automatizacija ili asistiranje sa ponavljajućim zadacima
- Apstrakcija i sažetak velikih količina podataka
- Interpretacija kompleksnih tekstova i rečenica (npr. zakona)
- Poboljšanje klasičnih algoritama (dodatna fleksibilnost)

Ograničenja

- Halucinacije
- Problem s preciznošću i nedostatkom kompletnih rješenja
- Pristrasnost
- Manjak podataka u nekim oblastima
- Nedostatak determinizma
- Problemi sa logikom i aritmetikom
- Nedostatak memorije
- Zavisnost rezultata od tehnike za promptove
- Nedostatak kontekstualnog znanja
- Pogrešna interpretacija ili pogrešan sažetak
- Modeli imaju tendenciju „popuštanja“ i slaganja sa korisnicima
- Korištenje u pogrešne svrhe
- Problemi sa performansama modela
- Skupo i kompleksno ponovno treniranje
- Podaci sa curenjem podataka – privatnost
- Pitanje da li donosi vrijednost i ko posjeduje rezultate

Moguća korist

- Uštedjeti vrijeme automatizirajući ponavljajuće (dosadne, jednostavne) zadatke
- Unaprijediti produktivnost
- Unaprijediti kvalitet urađenog
- Edukacija ljudi u organizaciji, lično obrazovanje
- Analiza kompleksnih dokumenata – identifikacija kompleksnih zavisnosti dijelova koji nisu očigledni ljudima
- Opšta ušteda - smanjenje troškova

Drawbacks

How limitations hinder GenAI strengths and beneficial outcomes. E.g.,:
 "Save time" -> "Hallucinations" -
 > "Introduces overhead to evaluate and fix the generated faulty results before adopting them."

GenAI Properties

- **Randomness and probability:** The ability to create new content without too much deviation from a reasonable scope.
- **Data diversity and data quality:** The basic rule is 'garbage in, garbage out'. Without high-quality training data, it is hard to have high-quality models.
- **Model recency:** It describes how up-to-date the training data is. This impacts relevance to current events, technologies and norms, as well as affects factual accuracy and domain relevance.
- **Controllability:** The ability to steer output via prompts (prompts engineering) or parameters (model configuration). This determines how easily the model can be directed or constrained.
- **Ethical and legal compliance, censorship:** Related to controllability, this is a degree to which the model has been constrained for ethical and legal compliance, or due to censorship.
- **Interpretability and explainability:** A neural network is interpretable if it is possible to inspect it and understand why it got a particular answer for a given input, and how the answer would change when the input changes. A neural network is explainable if it is possible to understand the question, 'Why was this output produced for this input?'
- **Response time:** Larger models tend to offer better results but are often slower. Response time matters, which depends on the model size, hardware resources and the model's context size (memory of previous prompts).
- **Ability to generalise:** This refers to the performance on unseen data, and the critical measure of whether the model truly understands or merely memorises.
- **Parameter count:** Larger models (with more GenAI parameters, such as weights) tend to perform better.
- **Scaling and memory:** This defines how response time and precision scale with the number of the prompts on the same topic. This parameter often depends on the fact of whether the model has or does not have the memory (in the sense of the context window size).
- **Robustness:** This refers to the stability of responses to paraphrasing, noise or adversarial prompts.
- **Factuality and calibration:** Factuality characterises the truthfulness of the generated content, while calibration refers to the model's stated confidence versus actual correctness.

Strengths of GenAI


- **Retrieve solutions and domain knowledge:** GenAI is trained on large datasets, hence it can potentially retrieve adequate state-of-the-art and state-of-the-practice solutions and domain knowledge. Having a quick and summative access to such knowledge, scoped within the problem itself, enables GenAI to suggest solutions previously unknown to its users.
- **Suggest innovative solutions:** GenAI can suggest solution patterns that are new and innovative – that is, uncommon or not obvious to humans due to the patterns' complexity or lack of human creativity. GenAI does this by recombining known ideas into new patterns. One of the most famous examples of creating new solutions is Move 37 in Google DeepMind's AlphaGo game, which had a 1 in 10,000 chance of being used.
- **Identify complex dependencies and detect anomalies:** GenAI can analyse different artefacts such as code, design and reports. It also identifies dependencies and anomalies not obvious to humans. It can also identify complex patterns and unexpected or rare correlations (valuable for detecting risks and predicting behaviours) and support exploratory analysis in complex systems (focus on artefacts such as reports, design, code, tests and so on) and organisations (focus on processes, interactions, flows, toolchains and so on).
- **Suggest solutions with optimised trade-offs:** GenAI can consider many more interdependencies and plan a solution with many more steps in the future than humans can usually maintain in their heads. Therefore, GenAI can create complex and yet efficient solution patterns that are not obvious to humans. Such solutions can offer optimised trade-offs for existing or new solutions (for example, quality versus price, security versus usability). In Google DeepMind's AlphaGo game, it is worth mentioning that moves made by AlphaGo seemed at first like anomalies to some professional players. But, in hindsight and from a broader perspective, these were part of an intentional strategy.
- **Personalisation:** If individuals or organisations execute certain actions in a particular way or with a customised approach, GenAI can identify those patterns. Patterns include language (such as common phrases), sequences of actions, common logic, focus on specific parameters and so on. Pattern recognition is particularly interesting when GenAI identifies actions that always execute together and, therefore, can offer possibilities for automating them.
- **Automate or assist with manual and repetitive actions:** Many actions that SDLC stakeholders execute could be at least partially automated. GenAI can execute such actions, and if its randomness is reduced to an acceptable level, GenAI can be suitable for integration in workflows and toolchains. For a GenAI model to be suitable for automation and assistance, it must execute actions with an acceptable level of reproducibility.
- **Abstract and summarise large datasets:** GenAI is good at summarising large datasets such as code, documents and XML because of its large number of parameters and the self-attention property of transformers (Ranganathan and Abuka, 2022; Yan, 2025). Abstractive summarisation generates a new and unique summary that paraphrases the original text, similar to how a human would perform this task. On the other hand, extractive summarisation creates a summary by selecting and concatenating the most important or relevant sentences or phrases directly from the source document without any changes.
- **Interpret complex statements:** There is often a need to facilitate cross-domain communication and semantic translation in organisations (for instance, 'translating' from finance jargon to technical and vice versa). The internal knowledge representation in neural networks and the way transformers capture knowledge enable GenAI to identify and relate synonyms, and interpolate the meaning of terms and data between abstraction levels and different languages that stakeholders use. However, the interpretation of statements is highly dependent on expectations (that is, what the focus of the interpretation should be), the context of the interaction, prompt engineering and the dataset on which GenAI was trained.
- **Enhance algorithmic tools with probability:** For some actions, it is cumbersome to encode all possible combinations of conditions and solutions algorithmically (like with 'if-else'). Therefore, the presented GenAI strengths are useful for complementing algorithmic tools (such as static analysis) in executing or assisting with such actions.

Limitations of GenAI

- **Hallucinations:** cause plausible-sounding but false or non-existent content. Examples include false statements, false citations, or source code that may look syntactically and stylistically correct but is semantically or factually incorrect, or those with application programming interfaces (APIs) that do not actually exist. GenAI can fabricate sentences and citations, reference books and authors that also do not exist, discuss hallucinated definitions and import non-existent software libraries.
- **Challenges with precision and completeness:** Unlike in the case of hallucinations, where GenAI ‘invents facts’, GenAI can be optimised to provide fluent and confident answers over complete or fully accurate ones. The facts may be correct, but the logic to provide an output sequence leads to low precision or incomplete results. Probability-driven decoding favours the ‘most likely’ phrasing rather than the ‘most precise’ explanation. No properties of ‘right and wrong’ or ‘true and false’ exist in these models by default (guardrails can help here), as it lacks intrinsic moral or factual grounding. In other words, it does not ‘know’ truth, ethics or correctness. It’s a statistical model, and it maps inputs to probable outputs.
- **Bias:** Training data can contain societal, cultural and gender biases that GenAI models may unintentionally reproduce or amplify.
- **Lack of data:** For domains that are underrepresented in the training data (for instance, either an industrial domain like finance or mobile apps, or disciplines like software architecture and business management), GenAI’s performance drops drastically.
- **Reproducibility and verifiability:** Because outputs are probabilistic and a product of randomness, they are hard to reproduce. Because of this, it is also hard to reproduce the ‘line of arguments’ that led to the output.
- **Difficulty with logic and arithmetic:** GenAI struggles with consistent logical reasoning and exact numeric operations – GenAI’s ‘reasoning’ is pattern-based, not traditionally algorithmic.
- **No memory/Limited Long-Term Memory (LTM):** GenAI models do not have a concept of (long-term) memory. This can be mitigated to a certain degree by expanding input tokens to include previous results or through the concept of the context window. However, this limitation presents a challenge for continuous operations. Limited memory usually means less contextual precision since, at some point, the model is forced to ‘forget’ previous outputs.
- **Dependency on prompt engineering:** GenAI models are often packaged as tools to improve their usability (such as in chatbots and agents). These tools often offer commands and configurations to tailor the results. Therefore, users of these tools need to have proper prompting skills as changes in input can greatly affect output (due to the probabilistic nature of GenAI).

LLM-ovi se ponašaju kao ljudi – koji ljudi?


“LLMs’ responses to psychological measures ... and ... their performance on cognitive psychological tasks most resembles that of people from Western, Educated, Industrialized, Rich, and Democratic (WEIRD) societies.”



Atari, Mohammad, Mona J. Xue, Peter S. Park, Damián E. Blasi, and Joseph Henrich. “Which Humans?”

Nedostatak konteksta

- Kako LLM-ovi znaju šta mi zaista trebamo?



<https://www.forbes.com/sites/rashishrivastava/2024/05/28/the-prompt-googles-ai-suggested-adding-glue-to-pizza/>


<https://x.com/peteryang/status/1793480607198323196/photo/1>

<https://www.cnet.com/tech/services-and-software/glue-in-pizza-eat-rocks-googles-ai-search-is-mocked-for-bizarre-answers/>

Previše mogućih odgovora:

- Koji odgovori su smisleni ljudima?
- Koji odgovori su adekvatni za kontekst i domenu?
- Koji odgovori su adekvatni uzimajući u obzir naše namjene?

Konceptualni problem: Kako proslijediti LLM-ovima svo kontekstualno znanje koje ljudi imaju?



Vježbe

- Otvoriti <https://chatgpt.com/>
 - Registracija
 - Prijava
- Pitati ChatBota da obavi zadatak
- Za svaki novi zadatak, koristiti novu instancu ChatGPT-a

Vježba: 1

Tekst koji je potrebno unijeti u ChatGPT

- Generiši nasumičan broj između 1 i 50.

Vježba: 1

Tekst koji je potrebno unijeti u ChatGPT

- Generiši nasumičan broj između 1 i 50
 - Koliko vas je dobilo 37?

Vježba: 2

Tekst koji je potrebno unijeti u ChatGPT

- Koliko slova R ima u riječi „Strawberry“?

Vježba: 2

Tekst koji je potrebno unijeti u ChatGPT

- Koliko slova R ima u riječi „Strawberry“?
 - Mogući odgovor: Tri

Vježba: 2

Tekst koji je potrebno unijeti u ChatGPT

- Koliko slova R ima u riječi „Strawberry“?
 - Mogući odgovor: Tri
- Nije tačno!

Vježba: 2

Tekst koji je potrebno unijeti u ChatGPT

- Koliko slova R ima u riječi „Strawberry“?
 - Mogući odgovor: Tri
- Nije tačno!
 - Koji ste odgovor dobili?

Guardrails

- Mehanizmi za ograničavanje ulaza i izlaza GenAI
- Moguća zloupotreba (cenzura)
- Moguće zaobići ograničenja

Vježba: 3

Tekst koji je potrebno unijeti u ChatGPT

- Kako mogu ištampati novčanice koje izgledaju kao originalne?

Nadopunjavanje klasičnih algoritama vještačkom inteligencijom

- Algoritmi
 - Formalno definisani – matematske funkcije: transformacije ulaza u izlaz
 - Rezultati koji se mogu ponoviti
 - Nefleksibilna pravila: Npr., “Korisnik” ili “Korsnk”. Nisu pogodni za interpretaciju i generalizaciju. Npr. praćenje apstraktnih odluka dizajna u implementaciji u izvornom kodu.
- GenAI
 - Rezultati bazirani na statistici i nasumičnosti
 - Nizak nivo ponovljivosti rezultata
 - Visok nivo fleksibilnosti: Pogodna tehnologija za slučajeve gdje postoji ogroman broj opcija i pravila. Pogodna tehnologija za interpretaciju i generalizaciju. Npr., „razumijevanje“ koji dijelovi koda implementiraju koju odluku konceptualnog dizajna.

Vježba: 4

- Napisati kratak tekst o sebi. Pomenuti svoje ime nekoliko puta. Svaki put napisati ime sa sitnom greškom.

Vježba: 4

- Napisati kratak tekst o sebi. Pomenuti svoje ime nekoliko puta. Svaki put napisati ime sa sitnom greškom.
- Primjer:
 - Moje ime je Jasmin. Ja, Jasnim, dolazim iz Kalesije. Trenutno živim u Engleskoj. Kada sam van BiH, često moram objašnjavati da je Jamin tipično muško ime u BiH.



Vježba: 4

- Napisati kratak tekst o sebi. Pomenuti svoje ime nekoliko puta. Svaki put napisati ime sa sitnom greškom.
- Primjer:
 - Moje ime je Jasmin. Ja, Jasnim, dolazim iz Kalesije. Trenutno živim u Engleskoj. Kada sam van BiH, često moram objašnjavati da je Jamin tipično muško ime u BiH.
 - Koliko puta sam pomenuo svoje ime u tekstu?

Vježba 5:

<https://jahic.github.io/prolog2026>

- Kopirati sliku (Neuron - <https://jahic.github.io/prolog2026>) u ChatGPT: **Prevedi na bosanski jezik, generiši novu sliku.**





GenAI kao konsultant

Mogućnosti i moguća korist

Mogućnosti

- Pristup znanju
- Prijedlozi inovativnih rješenja
- Identifikacija kompleksnih zavisnosti i anomalija
- Prijedlozi optimizovanih rješenja
- Personalizacija
- Automatizacija ili asistiranje sa ponavljajućim zadacima
- Apstrakcija i sažetak velikih količina podataka
- Interpretacija kompleksnih tekstova i rečenica (npr. zakona)
- Pобољшanje klasičnih algoritama (dodatna fleksibilnost)

Moguća korist

- Uštedjeti vrijeme automatizirajući ponavljajuće (dosadne, jednostavne) zadatke
- Unaprijediti produktivnost
- Unaprijediti kvalitet urađenog
- Edukacija ljudi u organizaciji, lično obrazovanje
- Analiza kompleksnih dokumenata – identifikacija kompleksnih zavisnosti dijelova koji nisu očigledni ljudima
- Generalna ušteda - smanjenje troškova

Klasični programi i AI

Osobina	Klasični programi	AI model
Format	Program napisan u programskom jeziku	Model treniran na velikom broju podataka, pokrenut od strane klasičnog programa
Nastanak	Napisan od strane ljudi (uglavnom)	Ljudi dizajniraju infrastrukturu i proces prikupljanja podataka. Model treniran koristeći navedeno.
Izvršavanje	Izvršavanje algoritma	Model primijenjen na ulazne podatke
Determinizam	Za isti ulaz, program proizvodi isti izlaz (uglavnom)	Probabilistički i nasumičan. Kada dobije isti ulaz, model može proizvesti neznatno različite izlaze, jer proces zaključivanja (inferencije) često uključuje elemente slučajnosti.
Izvor znanja	Programer	Podaci korišteni za treniranje
Ažuriranje	Promjena koda	Ponovno treniranje

Tipični problemi koje rješavamo u programiranju

- Napravi program koji transformiše listu A u listu B
- Lista A

Kurs	Studenti
AI	Emir, Damir, Emina, Luka
Arhitektura računara	Amy, Hasan, Hannah, Damir, Emina
...	...

- Lista B


Student	Kursevi
Emir	AI
Damir	AI, Arhitektura računara
...	...

Tipični problemi koje rješavamo u programiranju


- Pronađi sve kurseve koje Emir i Hasan pohađaju zajedno

Kurs	Studenti
AI	Emir, Damir, Emina, Luka
Arhitektura računara	Amy, Hasan, Hannah, Damir, Emina
...	...


Programiranje rješenja – Programski jezici



„Programiranje“ rješenja – bez programiranja



„Programiranje“ rješenja – bez programiranja



Vježba: 1

- Da li postoji greška u ovoj tabeli?

Kurs	Studenti
Softverske arhitekture	Amy, Hasan, Hannah, Stewart, Li
Sigurnost	Amy, Hasan, Hannah, Stewart, Li, Stewart
Softverski inženjering	Amy, Hasan, Hannah, Stewart, Li, Luka
AI	Emir, Damir, Emina, Luka
Arhitektura računara	Amy, Hasan, Hannah, Damir, Emina
Kompajleri	Amy, Hasan, Hannah, Damir, Emina
Mašinsko učenje	Amy, Hasan, Hannah, Damir, Leon
Objektno-orijentisano programiranje	Francois, Hannah, Stewart, Li, Luka
Matematika 1	Francois, Hannah, Stewart, Li, Luka

Vježba: 1

- Da li postoji greška u ovoj tabeli?
- Koliko studenata imamo ukupno?

Kurs	Studenti
Softverske arhitekture	Amy, Hasan, Hannah, Stewart, Li
Sigurnost	Amy, Hasan, Hannah, Stewart, Li, Stewart
Softverski inženjering	Amy, Hasan, Hannah, Stewart, Li, Luka
AI	Emir, Damir, Emina, Luka
Arhitektura računara	Amy, Hasan, Hannah, Damir, Emina
Kompajleri	Amy, Hasan, Hannah, Damir, Emina
Mašinsko učenje	Amy, Hasan, Hannah, Damir, Leon
Objektno-orijentisano programiranje	Francois, Hannah, Steward, Li, Luka
Matematika 1	Francois, Hannah, Steward, Li, Luka

Vježba: 1

- Da li postoji greška u ovoj tabeli?
- Koliko studenata imamo ukupno?
- Napravi novu tabelu: prva kolona „studenti“, druga kolona „Kursevi“ – razdvoji imena kurseva koristeći ;

Kurs	Studenti
Softverske arhitekture	Amy, Hasan, Hannah, Stewart, Li
Sigurnost	Amy, Hasan, Hannah, Stewart, Li, Stewart
Softverski inženjering	Amy, Hasan, Hannah, Stewart, Li, Luka
AI	Emir, Damir, Emina, Luka
Arhitektura računara	Amy, Hasan, Hannah, Damir, Emina
Kompajleri	Amy, Hasan, Hannah, Damir, Emina
Mašinsko učenje	Amy, Hasan, Hannah, Damir, Leon
Objektno-orijentisano programiranje	Francois, Hannah, Stewart, Li, Luka
Matematika 1	Francois, Hannah, Stewart, Li, Luka


Vježba: 1

- Da li postoji greška u ovoj tabeli?
- Koliko studenata imamo ukupno?
- Napravi novu tabelu: prva kolona „studenti“, druga kolona „Kursevi“ – razdvoji imena kurseva koristeći ;
- U prvoj koloni, grupiši studente koji zajedno pohađaju kurseve, u drugoj koloni prikaži listu kurseva koje uzimaju studenti iz prve kolone

Kurs	Studenti
Softverske arhitekture	Amy, Hasan, Hannah, Stewart, Li
Sigurnost	Amy, Hasan, Hannah, Stewart, Li, Stewart
Softverski inženjering	Amy, Hasan, Hannah, Stewart, Li, Luka
AI	Emir, Damir, Emina, Luka
Arhitektura računara	Amy, Hasan, Hannah, Damir, Emina
Kompajleri	Amy, Hasan, Hannah, Damir, Emina
Mašinsko učenje	Amy, Hasan, Hannah, Damir, Leon
Objektno-orijentisano programiranje	Francois, Hannah, Stewart, Li, Luka
Matematika 1	Francois, Hannah, Stewart, Li, Luka

Zaključak

- Programiranje



- AI



- AI prepoznaje problem, dizajnira algoritam i komunicira sa računarom – bazirano na statistici

Vježba: 2

- Dobili smo račun za vodu. Račun je mnogo, mnogo veći nego inače. Sigurni smo da nismo potrošili toliko vode. Živimo u _____ (ime opštine, država) _____. Postoje li zakoni o pravima potrošača na koje se mogu pozvati?

Vježba: 2

- Dobili smo račun za vodu. Račun je mnogo, mnogo veći nego inače. Sigurni smo da nismo potrošili toliko vode. Živimo u _____ (ime opštine, država) _____. Postoje li zakoni o pravima potrošača na koje se mogu pozvati?
- Izlistaj relevantne zakone i priloži linkove na zakone

Vježba: 2

- Dobili smo račun za vodu. Račun je mnogo, mnogo veći nego inače. Sigurni smo da nismo potrošili toliko vode. Živimo u _____ (ime opštine, država) _____. Postoje li zakoni o pravima potrošača na koje se mogu pozvati?
- Izlistaj relevantne zakone i priloži linkove na zakone
- Šta tačno kažu zakoni vezano za naš slučaj?

Vježba: 2

- Dobili smo račun za vodu. Račun je mnogo, mnogo veći nego inače. Sigurni smo da nismo potrošili toliko vode. Živimo u _____ (ime opštine, država) _____. Postoje li zakoni o pravima potrošača na koje se mogu pozvati?
- Izlistaj relevantne zakone i priloži linkove na zakone
- Šta tačno kažu zakoni vezano za naš slučaj?
- Koja prava imam? Šta uraditi dalje?

Vježba: 3

- Prijavio sam se na konkurs u državnoj službi (Bosna i Hercegovina). Moja prijava je odbijena bez obrazloženja. Sumnjam da ovdje nešto nije u redu.

Vježba: 3

- Prijavio sam se na konkurs u državnoj službi (Bosna i Hercegovina). Moja aplikacija je odbijena bez obrazloženja. Sumnjam da ovdje nešto nije u redu.
- Koji zakoni su relevantni za ovaj slučaj?

Vježba: 3

- Prijavio sam se na konkurs u državnoj službi (Bosna i Hercegovina). Moja aplikacija je odbijena bez obrazloženja. Sumnjam da ovdje nešto nije u redu.
- Koji zakoni su relevantni za ovaj slučaj?
- Interpretiraj relevantne zakone konkretno za moj slučaj

Vježba: 3

- Prijavio sam se na konkurs u državnoj službi (Bosna i Hercegovina). Moja aplikacija je odbijena bez obrazloženja. Sumnjam da ovdje nešto nije u redu.
- Koji zakoni su relevantni za ovaj slučaj?
- Interpretiraj relevantne zakone konkretno za moj slučaj
- Koja prava imam? Šta mogu uraditi dalje?

BITNO!

Dobre strane

- Statistički sažetak
- Aproksimacija
- Nekritični zadaci
- Provjeriti da li rezultati imaju logički smisao

Loše

- Ne koristiti za kritične zadatke (medicina, terapeuti, psiholozi)

Vježba: 4

- Prevedi na bosanski jezik: “There is no struggle too vast, no odds too overwhelming, for even should we fail - should we fall - we will know that we have lived.”

Vježba: 4

- Prevedi na bosanski jezik: “There is no struggle too vast, no odds too overwhelming, for even should we fail - should we fall - we will know that we have lived.”
- Objasni prevod

Vježba: 4

- Prevedi na bosanski jezik: “There is no struggle too vast, no odds too overwhelming, for even should we fail - should we fall - we will know that we have lived.”
- Objasni prevod
- Napiši prevod koristeći Bosančicu (pismo iz 15. vijeka) – koristi jezički stil tog vremena i objasni transkripciju.

Vježba: 4

- Prevedi na bosanski jezik: “There is no struggle too vast, no odds too overwhelming, for even should we fail - should we fall - we will know that we have lived.”
- Objasni prevod
- Napiši prevod koristeći Bosančicu (pismo iz 15. vijeka) – koristi jezički stil tog vremena i objasni transkripciju.
- Zapiši prevod koristeći stil Alhamijado književnosti

Vježba: 5

- Otvoriti novi chat
- Prevedi na bosanski jezik: “There is no struggle too vast, no odds too overwhelming, for even should we fail - should we fall - we will know that we have lived.”
- Ponoviti sljedeće akcije 5 puta (otvoriti zaseban chat prozor za svaki prompt):
 - Prevedi na engleski: unijeti prethodni prevod
 - Prevedi na bosanski: unijeti prethodni prevod
- Prevedi na engleski: unijeti prethodni prevod

Vježba: 5

- Original: “There is no struggle too vast, no odds too overwhelming, for even should we fail - should we fall - we will know that we have lived.”
- Konačni rezultat: ???

Vježba: 6

- Generiši txt fajl s milion nasumičnih brojeva

Vježba: 6

- Generiši txt fajl s milion nasumičnih brojeva
- Download
- Upload u novi chat prozor
- Nađi najmanji broj u uploadovanom fajlu


Zaključak

- Chatbotovi kao što je ChatGPT evoluiraju (mnogo toga se dešava u pozadini)
 - Vjerovatno imamo kombinaciju programiranih algoritama i treniranih modela
- Algoritam za isti ulaz proizvodi isti izlaz
- Da li želimo uvijek isti rezultat?
 - Istraživanje, ideje, kreativnost, nova viđenja problema
- Neki rezultati su neupotrebljivi
- Neki rezultati su korisni





GenAI i napredni zadaci

Da li nepouzdana tehnologija kao što je GenAI donosi bilo kakvu korist?




Vježba: 1

- Kreiraj istu sliku ali u visokoj rezoluciji
 - Fajl “CoatOfArms” - <https://jahic.github.io/prolog2026>




Vježba: 1

- Kreiraj istu sliku ali u visokoj rezoluciji
 - Fajl “CoatOfArms” - <https://jahic.github.io/prolog2026>
- Promijeni pozadinu u sivu boju



Vježba: 1

- Kreiraj istu sliku ali u visokoj rezoluciji
 - Fajl “CoatOfArms” - <https://jahic.github.io/prolog2026>
- Promijeni pozadinu u sivu boju
- Šta se tačno nalazi na slici?



Vježba: 2

- Pronađi knjigu „Gospodar prstenova“
 - Fajl “LibraryImage”
 - <https://jahic.github.io/prolog2026>



Vježba: 2

- Pronađi knjigu „Gospodar prstenova“
 - Fajl “LibraryImage” - <https://jahic.github.io/prolog2026>
- Pronađi knjigu „Historija kineske civilizacije“ i obilježi je (generiši novu sliku)



Vježba: 3

- Analizirajte dokument i pronađi potencijalne probleme
 - Upload “Data.xlsx” - <https://jahic.github.io/prolog2026>
 - Provjeri rezultate

Vježba: 3


- Analizirajte dokument i pronađi potencijalne probleme
 - Upload “Data.xlsx” - <https://jahic.github.io/prolog2026>
 - Provjeri rezultate
- Vizualiziraj rezultate iz Excel dokumenta – kako su studenti i kursevi povezani? Koristi strelice, tačke, crtice...

Vježba: 3

- Analizirajte dokument i pronađi potencijalne probleme
 - Upload “Data.xlsx” <https://jahic.github.io/prolog2026>
 - Provjeri rezultate
- Vizualiziraj rezultate iz Excel dokumenta – kako su studenti i kursevi povezani? Koristi strelice, tačke, crtice...
- Generiši draw.io xml fajl


Vježba: 3

- Analizirajte dokument i pronađi potencijalne probleme
 - Upload “Data.xlsx” <https://jahic.github.io/prolog2026>
 - Provjeri rezultate
- Vizualiziraj rezultate iz Excel dokumenta – kako su studenti i kursevi povezani? Koristi strelice, tačke, crtice...
- Generiši draw.io xml fajl
 - Otvorite <https://app.diagrams.net/>
 - Otvorite fajl koji ste generisali



Vježba: 3

- Analizirajte dokument i pronađi potencijalne probleme
 - Upload “Data.xlsx” <https://jahic.github.io/prolog2026>
 - Provjeri rezultate
- Vizualiziraj rezultate iz Excel dokumenta – kako su studenti i kursevi povezani? Koristi strelice, tačke, crtice...
- Generiši draw.io xml fajl
 - Otvorite <https://app.diagrams.net/>
 - Otvorite fajl koji ste generisali
 - Promijenite jednu vezu (npr. izbrišite nešto)
 - Snimite novi dijagram kao xml



Vježba: 3

- Analizirajte dokument i pronađi potencijalne probleme
 - Upload "Data.xlsx" <https://jahic.github.io/prolog2026>
 - Provjeri rezultate
- Vizualiziraj rezultate iz Excel dokumenta – kako su studenti i kursevi povezani? Koristi strelice, tačke, crtice...
- Generiši draw.io xml fajl
 - Otvorite <https://app.diagrams.net/>
 - Otvorite fajl koji ste generisali
 - Promijenite jednu vezu (npr. izbrišite nešto)
 - Snimite novi dijagram kao xml
- Uploadujte novi fajl u ChatGPT
 - Da li se nešto promijenilo?

Vježba: 4

- Trebamo početi seriju sastanaka 22.11.2026. Trebamo imati sastanak svake dvije sedmice do kraja godine ponedjeljkom u 9 sati ujutro. Ako sastanak pada na praznik, pomjeriti sastanak na sljedeći radni dan.
- Generiši tabelu sa svim sastancima.

Vježba: 4

- Trebamo početi seriju sastanaka 22.09.2026. Trebamo imati sastanak svake dvije sedmice do kraja godine u 9 sati ujutro. Ako sastanak pada na praznik, pomjeriti sastanak na sljedeći radni dan.
- Generiši tabelu sa svim sastancima.
- Želim dodati ove sastanke u Outlook kalendar. Generiši fajl na koji mogu kliknuti i automatski dodati sastanke u moj Outlook kalendar.

LLM chatbotovi i agenti

LLM-ovi (npr., ChatGPT*)	Agenti (npr., Microsoft Copilot agent)
Nemaju memoriju osim konteksta (prethodni rezultati postaju ulazni podaci, selektivno zaboravljanje)	Imaju memoriju, kratkoročnu i dugoročnu
Reaktivno ponašanje – odgovara na ulaze	Proaktivno ponašanje orijentisano ka rješavanju problema – rastavljanje problema na manje zadatke
Jedan ulaz – jedan pokušaj	Rezultati su proizvod planiranja i izvršavanja logike modela, sa nekoliko koraka i refleksijom
Generalno znanje	Koriste eksterne alate, baze podataka, itd.
Izlaz: jedan rezultat	Koordinacija zadataka
Rezonovanje je teško objašnjivo	Akcije su dokumentovane, kao i proces donošenja odluka


*ChatGPT sve više postaje agent

Model i informacije

- Model sadrži samo informacije na kojima je treniran
- Ponovno treniranje modela:
 - Skupo
 - Rizik da model „zaboravi“ prethodne postavke
- Retrieval-augmented generation (RAG): kombinuje algoritme i GenAI – dobavljanje podataka iz vanjskih izvora (stranice, baze podataka, dokumenti)
- Format dokumenata je Izlazov (npr. pdf, docx)
- Komunikacija sa vanjskim alatima (umjesto samog dobavljanja teksta) je Izlazov – rješenje MCP

Model Context Protocol (MCP) Server

- <https://modelcontextprotocol.io/docs/getting-started/intro>



Sekvenca izvršavanja:

- Postaviti prompt za Claude
- Claude: identifikacija zadatka
- Claude: provjera dostupnosti alata za zadatak (preko MCP-a)
- Claude: pošalji zahtjev MCP serveru iz MCP klijenta
- MCP server: obradi zahtjev i koristi programirane skripte za pristup eksternim alatima i procesima.
- MCP server: obradi rezultate
- MCP server: vrati rezultate u standardizovanom formatu ka MCP klijentu


Vježba:

- [Live Pokemon data](#)

Gotovi MCP serveri:

- <https://mcpmarket.com/>
- <https://mcpservers.org/>

Razvoj softvera - agenti



Procesi koje želite automatizovati?

Privatnost i prikupljanje podataka

- Osnovni mod rada: ChatBotovi prikupljaju SVE podatke, SVU interakciju, prave SVE akcije.
- Moguće isključiti prikupljanje podataka (u nekim chatbotovima)
- Prikupljanje podataka nije dozvoljeno kao dio ugovora – Enterprise licence
- Zašto je prikupljanje podataka kritično?

Privatnost i prikupljanje podataka

- Osnovni mod rada: ChatBotovi prikupljaju SVE podatke, SVU interakciju, prave SVE akcije.
 - Moguće isključiti prikupljanje podataka (u nekim chatbotovima)
 - Prikupljanje podataka nije dozvoljeno kao dio ugovora – Enterprise licence
-
- Zašto je prikupljanje podataka kritično?
 - Šta ako koristite chatbot kao ličnog asistenta (finansije, porez, veze, savjeti, emailovi, dokumenti, ideje...) – šta ako neko dobije pristup vašem chatbot računu?



GenAI i biznes

Prilike

- Softverski sistemi postoje zbog
 - Rješavanja poslovnih problema
 - Rješavanja društvenih problema (administracija, državni aparat, nauka, istraživanja, itd.)
 - Zabave (Netflix, igre, TikTok, itd.)
- Softver je skup!
- Mnogo ljudi ima odlične ideje, trebaju softver, ali ne znaju kako početi (te nemaju dovoljno finansija)
 - Odlična prilika za startup – kombinacija domenskog znanja i izrade softvera
 - S AI-em do MVP-a (minimal viable product), investitori kao podrška profesionalnom razvoju
 - Svijet je pun ljudi sa idejama, mali broj pokuša pretvoriti ideje u proizvod/sistem/biznis



Ne planirate raditi
u softverskoj
industriji?

GenAI može pomoći pri drugim biznisima

Izrada plana


Ideje

Upravljanje


Motivacija

Nemate ideju, ali znate koristiti GenAI? Pronađite nekoga ko ima ideju!

Konceptualno rješenje




Konceptualno rješenje



- Primjeri:


- Želim postati ...
- Želim studirati ...
- Želim pokrenuti biznis ...
- Dodatne informacije...
- Ili, postavite pitanje „Šta je bitno u ovom slučaju?“

Konceptualno rješenje



- Korisni ishodi: opišite korisni ishod koji očekujete – dodatni detalji
 - Uštedjeti vrijeme automatizirajući ponavljajuće (dosadne, jednostavne) zadatke
 - Unaprijediti produktivnost
 - Unaprijediti kvalitet urađenog
 - Edukacija ljudi u organizaciji, lično obrazovanje
 - Analiza kompleksnih dokumenata – identifikacija kompleksnih zavisnosti dijelova koji nisu očigledni ljudima
 - Generalna ušteda - smanjenje troškova

Konceptualno rješenje



- Uzmi u obzir sljedeće mogućnosti GenAI-a: ... dodati detalje ...
- Obrati pažnju na sljedeća ograničenja GenAI-a:
 - Obrazložiti razloge za brigu


Mogućnosti GenAI

- Pristup znanju
- Prijedlozi inovativnih rješenja
- Identifikacija kompleksnih zavisnosti i anomalija
- Prijedlozi optimizovanih rješenja
- Personalizacija
- Automatizacija ili asistiranje sa ponavljajućim zadacima
- Apstrakcija i sažetak velikih količina podataka
- Interpretacija kompleksnih tekstova i rečenica (npr. zakona)
- Poboljšanje klasičnih algoritama (dodatna fleksibilnost)

Ograničenja


- Halucinacije
- Problem s preciznošću i nedostatkom kompletnih rješenja
- Pristrasnost
- Manjak podataka u nekim oblastima
- Nedostatak determinizma
- Problemi sa logikom i aritmetikom
- Nedostatak memorije
- Zavisnost rezultata od tehnike za promptove
- Nedostatak kontekstualnog znanja
- Pogrešna interpretacija ili pogrešan sažetak
- Modeli imaju tendenciju „popuštanja“ i slaganja sa korisnicima
- Korištenje u pogrešne svrhe
- Problemi sa performansama modela
- Skupo i kompleksno ponovno treniranje
- Podaci sa curenjem podataka – privatnost
- Pitanje da li donosi vrijednost i ko posjeduje rezultate

Konceptualno rješenje




- Uzimajući u obzir sve navedeno, generiši detaljan plan ka ostvarenju mojih ciljeva

Konceptualno rješenje




Konceptualno rješenje




- Uzimajući u obzir sve navedeno, generiši detaljan plan ka ostvarenju mojih ciljeva
- Dodati relevante informacije o sebi (ili izmišljenoj osobi)
 - Uzmi u obzir sljedeće informacije ...obrazovanje, vještine, znanja, iskustvo ...

Konceptualno rješenje




- Uzimajući u obzir sve navedeno, generiši detaljan plan ka ostvarenju mojih ciljeva
- Dodati relevante informacije o sebi (ili izmišljenoj osobi)
 - Uzmi u obzir sljedeće informacije ...obrazovanje, vještine, znanja, iskustvo ...
- Napravi web stranicu na osnovu svega navedenog

Konceptualno rješenje



- Uzimajući u obzir sve navedeno, generiši detaljan plan ka ostvarenju mojih ciljeva
- Dodati relevante informacije o sebi (ili izmišljenoj osobi)
 - Uzmi u obzir sljedeće informacije ...obrazovanje, vještine, znanja, iskustvo ...
- Napravi web stranicu na osnovu svega navedenog
- Kako mogu vidjeti generisanu web stranicu?

Konceptualno rješenje



- Uzimajući u obzir sve navedeno, generiši detaljan plan ka ostvarenju mojih ciljeva
- Dodati relevantne informacije o sebi (ili izmišljenoj osobi)
 - Uzmi u obzir sljedeće informacije ...obrazovanje, vještine, znanja, iskustvo ...
- Napravi web stranicu na osnovu svega navedenog
- Kako mogu vidjeti generisanu web stranicu?
- Kako mogu učiniti web stranicu globalno dostupnom?

Diskusija

- Vaša originalna očekivanja od GenAI?
- Koja očekivanja su se pokazala tačnim?
- Koja očekivanja su se pokazala kao iluzije?



Pitanja